

Slide 1: 封面 (Title Slide)

[居中排版]

基于强化学习的生成式检索

Generative Retrieval via Reinforcement Learning

汇报人：晁恒

日期：2026年4月7日

单位：[您的学院/实验室名称]

Slide 2: 研究背景与目标 (Background & Objectives)

[布局：左侧流程图 | 右侧任务列表]

核心背景

- **输入 (Input):** 用户输入的 Query 通常是模糊、不完整或缺乏关键语义的。
- **目标 (Output):** 利用大语言模型（LLM）进行重写，生成能**准确命中**目标信息的清晰 Query。

研究任务

1. **理论建模：** 设计面向生成式检索的 MDP（马尔可夫决策过程）模型。
2. **算法优化：** 实现基于 **GRPO**（Group Relative Policy Optimization）的强化学习算法。
3. **闭环验证：** 完成代码开发、实验对比及学术论文撰写。

Slide 3: 理论建模：面向生成式检索的 MDP 设计

[布局：三栏并列]

状态 (State, S_t)	动作 (Action, A_t)	奖励 (Reward, R)
定义： 初始 Query Prompt + 当前已生成的 Token 序列。	定义： 词表上的概率分布。	定义： 序列结束后的延迟奖励。
含义： 模型决策的上下文环境，随生成进程动态更新。	含义： 模型决定生成的下一个词 (Token)。	含义： 结合检索质量 (MRR) 与文本约束的综合得分。

Slide 4: 核心算法：GRPO 的优势函数与“去 Critic”化

[布局：左侧对比图 | 右侧公式解析]

为什么选择 GRPO?

- **PPO 的痛点：** 必须训练额外的 Critic 网络来估算 Value，显存开销极大 (1.5x~2x)。
- **GRPO 的创新： 组内相对优势。** 对同一个 Query 采样 G 个样本，通过组内得分标准化代替 Critic。

核心公式

$$A_i = \frac{r_i - \mu}{\sigma + \epsilon}$$

变量含义：

- r_i ：第 i 个采样回答的奖励得分。

Slide 5: 核心算法: GRPO 的目标函数与 KL 正则约束

损失函数分解

1. 裁剪代理目标 (Clipped Surrogate Objective):

$$L_{GRPO} = \mathbb{E} \left[\min \left(\frac{\pi_{\theta}}{\pi_{old}} A_i, \text{clip} \left(\frac{\pi_{\theta}}{\pi_{old}}, 1 - \epsilon, 1 + \epsilon \right) A_i \right) \right]$$

- **蓝色标记:** 鼓励生成带来高优势 A_i 的 Token。
- **红色标记:** 限制更新幅度, 防止策略偏移过快导致“学崩”。

2. 引入 KL 散度惩罚的总损失:

$$L = L_{GRPO} - \beta \cdot KL(\pi_{\theta} || \pi_{ref})$$

- **绿色标记 (KL 散度):** 正则项。惩罚新策略偏离参考模型过远, 防止产生不可读的乱码或过度拟合奖励。

Slide 6: 奖励函数设计 (Reward Engineering)

[布局：视觉化的权重分配图]

总奖励 = 检索奖励 + 保真奖励 - 文本惩罚

- **检索质量驱动 (Core):**
 - 基于 Pyserini BM25 检索器。
 - 计算 MRR@10 (Mean Reciprocal Rank)，确保改写后的 Query 能排在相关文档前列。
- **文本保真约束:**
 - 利用 Jaccard 相似度 计算词面重叠，防止模型“放飞自我”篡改原意。
- **质量惩罚机制 (Sanity Check):**
 - **长度惩罚:** 避免过长或过短。
 - **重复惩罚:** 阻断 Token 循环生成。
 - **不可读字符惩罚:** 保持生成文本的自然性

Slide 7: 实验设计与评估方案 (Experimental Design)

实验设置

- 数据集： MS MARCO Passage Ranking （权威机器阅读理解与检索基准）。
- 模型规格： 基于 0.5B / 1.5B 参数规模的 LLM 跑通端到端流程。

三路对比实验 (Baselines)

方案	说明	预期效果
Original Baseline	原始模糊 Query 直接检索	基准分
Zero-shot LLM	基础模型直接改写 (无 RL)	提升语义，但缺乏检索针对性
RL-trained (Ours)	经 GRPO 优化后的模型	最优： 兼顾语义与检索性能

Slide 8: 总结与目前已完成工作 (Summary)

阶段性成果

- **理论贡献：** 成功将 GRPO 算法适配至生成式检索任务，建立了高效的“去 Critic”训练范式。
- **工程实现：**
 - 搭建了基于 Transformer + Pyserini 的闭环 RL 训练框架。
 - 在小规模模型上验证了奖励函数收敛的有效性。

未来计划

1. **规模化扩展：** 在更高参数规模（如 7B/14B）模型上进行消融实验。
2. **指标深挖：** 进一步分析 KL 散度与检索准确率之间的 Pareto 边界。
3. **论文撰写：** 整理实验数据，完成最终学术论文。

感谢各位老师的聆听！ 请批评指正。